

基于 PLS 和 ε -FT 的电站锅炉 NO_x 排放特性研究

张文广¹, 张越²

(1. 华北电力大学 新能源电力系统国家重点实验室, 北京 102206;

2. 华北电力大学 工业过程测控新技术与系统北京市重点实验室, 北京 102206)

摘要: 为了有效地控制电站锅炉的 NO_x 排放量, 以某 600MW 电站锅炉历史数据为样本, 应用偏最小二乘 (PLS) 和 ε -模糊树 (ε -FT) 方法建立了 NO_x 排放特性预测模型。针对热工过程变量之间的强相关性和耦合性, 采用 PLS 对模型输入热工数据进行重要变量信息提取和变量选择, 将得到的最优变量作为 ε -FT 模型的输入, 建立了 NO_x 排放的 PLS- ε -FT 模型, 并将模型与其他建模方法进行了对比, 结果表明该模型通过 PLS 进行变量选择, 消除了变量的相关性, 降低了模型的维数和复杂程度, 提高了模型的预测精度和泛化能力。

关键词: 电站锅炉; NO_x 排放; 偏最小二乘; ε -模糊树; 变量选择

Study on NO_x Emission of Utility Boilers Based on Partial Least Squares and ε -Fuzzy Tree Method

ZHANG Wen-guang¹, ZHANG Yue²

(1. State Key Laboratory of Alternate Electrical Power System with Renewable Energy Sources, North China Electric Power University, Beijing 102206, China; 2. Beijing Key Laboratory of New Technology and System on Measuring and Control for Industrial Process, North China Electric Power University, Beijing 102206, China)

Abstract: To control the NO_x emission from utility boiler effectively, the prediction model of NO_x emission is established based on the historical data of a 600MW coal-fired boiler by partial least squares (PLS) and ε -fuzzy tree (ε -FT). Considering the strong correlations and coupling of input variables in thermal power process, PLS method is applied to extract important variables information and select variables for input thermal data of model. Subsequently, the obtained feature matrix is used as the input of ε -FT to establish the PLS- ε -FT model of NO_x emission. The model is compared with other modeling methods. The results reveal that the variable correlations is eliminated, the model complexity and the number of the variable dimensions are decreased, and the prediction accuracy and generalization ability of the model are enhanced through PLS variable selection.

Key words: utility boiler; NO_x emission; PLS; ε -FT; variable selection

随着国家对环保要求的日益严格, 降低污染物排放已经成为燃煤电站面临的重要问题。氮氧化物 (NO_x) 是一种危害身体健康和破坏环境的有毒气体, 其 50% 以上来源于燃煤电站^[1]。因此, 控制燃煤电站 NO_x 的排放具有重要意义。

在燃烧过程中, NO_x 的生成机制非常复杂, 受多个变量的限制和影响, 这使得建立 NO_x 排放的机理模型非常复杂。随着人工智能技术的发展, NO_x 排放特性研究进入了崭新的阶段, 特别是基

于人工神经网络 (ANN) 和支持向量机 (SVM) 建立 NO_x 排放模型引起了众多学者的广泛关注。其中, 部分学者^[2,3]采用不同的优化算法对 SVM 中的未知参数进行寻优, 从而建立了预测性能较好的 NO_x 排放模型; 一些学者^[4,5]为了缩短建模时间和提高建模精度, 采用最小二乘支持向量机 (LSSVM) 进行 NO_x 排放建模。但是, ANN 模型存在训练时间长, 随机性大, 易陷入局部极小和过学习等问题^[6]; SVM 模型在处理大样本集时

收稿日期: 修订日期:

基金项目: 国家重点基础研究发展计划 (973 计划) 资助项目 (2012CB215203); 中央高校基本科研业务费专项资金资助 (2015MS33)

作者简介: 张文广 (1975—), 男, 山东海阳人, 副教授, 博士, 研究方向为: 燃煤机组燃烧优化。电话 (Tel.): 010-61772843;

E-mail: zwg@ncepu.edu.cn.

会出现训练时间长, 计算量大的缺点^[7], 算法中的核函数参数和正规化参数的确定也增加了算法的难度。

近年来, 毛剑琴等^[8]提出了基于树结构的自适应模糊推理辨识方法 (ATSFIS), 简称“模糊树 (FT)”。这种算法利用输入数据的特征信息对空间进行自适应划分, 将规则中前件和后件参数同时进行训练和优化, 简化了计算, 在一定程度上避免了“维数灾”引起的“规则爆炸”, 适合处理高维复杂非线性、强耦合系统的建模问题^[9,10]。随后, 为了提高这种算法辨识噪声和异常值的能力, 一种具有较强鲁棒性的 ε -模糊树 (ε -FT) 方法被研究^[11]。这种算法继承了 FT 的优点, 并展示了更强的鲁棒性。

在热工过程中, 变量之间存在着强相关性和耦合性, 一个变量受多个变量的影响, 并存在一定的非线性关系, 筛选出一个变量的最优相关变量, 有利于剔除变量间干扰和降低模型的复杂程度。偏最小二乘 (PLS) 是集多元统计回归、典型相关分析和主成分分析的基本功能为一体的一种新型数据分析方法, 能够很好的选择出与因变量相关性最大的自变量组合, 通过主元分析更好的解释各自变量对因变量的贡献作用, 克服变量之间的相关性。

本文通过 PLS 对热工过程的历史数据进行重要变量信息提取和变量选择, 将得到的最优变量作为模型输入, 建立了 NO_x 的 PLS- ε -FT 模型, 并将该模型与其他方法所建模型进行了对比。结果表明, 所建立的模型降低了模型的复杂程度, 提高了预测精度和泛化能力。

1 PLS 原理

1.1 PLS 理论与算法

设样本集合 $\{x_i, y_i\}_{i=1}^M$, 自变量个数为 p , $x_i \in R^{M \times p}$, $y_i \in R^{M \times 1}$, 经过相应的标准化处理后记为 E_0 和 F_0 。PLS 具体步骤如下:

(1) 分别提取量变量组的第一对主成分 t_1 和 u_1 , 使之相关性达最大, 并要求主成分 t_1 和 u_1 尽可能多地提取所在变量组的变异信息。计算第一对主成分的得分向量为:

$$\hat{t}_1 = E_0 w_1 \quad (1)$$

$$\hat{u}_1 = F_0 v_1 \quad (2)$$

将上述要求转化为数学上的条件极值问题有:

$$\begin{cases} \max \langle E_0 w_1, F_0 v_1 \rangle \\ w_1^T w_1 = 1, v_1^T v_1 = 1 \end{cases} \quad (3)$$

(2) 建立 t_1 的回归模型为:

$$\begin{cases} E_0 = \hat{t}_1 \alpha_1^T + E_1 \\ F_0 = \hat{t}_1 \beta_1^T + F_1 \end{cases} \quad (4)$$

式中, α_1 和 β_1 为模型的回归参数向量。表达式如下:

$$\begin{cases} \alpha_1 = E_0^T \hat{t}_1 / \|\hat{t}_1\|^2 \\ \beta_1 = F_0^T \hat{t}_1 / \|\hat{t}_1\|^2 \end{cases} \quad (5)$$

(3) 用残差阵 E_0 和 F_0 重复上述步骤, 求取第二主成分 t_2 , 并依次求取下去, 直至求取到由交叉有效性原则确定最终的主成分个数为止。

(4) 交叉有效性验证

一般情况下, PLS 并不需要选出所有存在的 r 个主成分, 而像主成分分析一样, 只选用前 l 个成分 ($l \leq r$), 即可得到预测能力较好的回归模型。对于要提取的主成分个数 l , 可以通过交叉有效性检验来确定。定义交叉有效性为:

$$Q_h^2 = 1 - \text{PRESS}(h) / SS(h-1) \quad (6)$$

定义抽取 h 个成分时因变量的预测误差平方和为:

$$\text{PRESS}(h) = \sum_{i=1}^M (y_i - \hat{y}_i(h))^2 \quad (7)$$

定义因变量的误差平方和为:

$$SS(h) = \sum_{i=1}^M (y_i - \hat{y}_{-i}(h))^2 \quad (8)$$

式中, y_i 为原始样本, $\hat{y}_i(h)$ 为使用全部样本点并提取 h 个成分进行建模后对样本点 i 的预测值, $\hat{y}_{-i}(h)$ 为删去样本点 i 并取 h 个成分进行建模后对样本点 i 的预测值。

当 $Q_h^2 \geq 0.0975$ 时, 表示提取的 t_h 成分的边际贡献显著^[12]。

1.2 自变量重要性指标

本文通过 PLS 使用变量投影重要性指标 (VIP) 来说明第 k 个自变量对因变量 y 的贡献作用, 其定义如下:

$$\text{VIP}_k = \sqrt{p \sum_{h=1}^m r^2(y; t_h) w_{hk}^2 / \sum_{h=1}^m r^2(y; t_h)} \quad (9)$$

式中, m 为主成分的个数; $r(y; t_h)$ 为 y 与 t_h 的相关系数; w_{hk} 为权值向量 w_h 的第 k 个分量。

2 ε -FT 原理及算法

ε -FT 方法具有建模精度高, 计算量小的优点, 适合处理高维复杂非线性、强耦合的系统建模问题。该算法通过采用 ε -不敏感学习方法求解模糊规则的后件参数, 增强了算法的鲁棒性, 能有效地辨识噪声和异常值。其具体算法如下:

S1: 设样本集 (x^i, y^i) , $i = 0, 1, \dots, M$, $x^i \in R^n$, $y^i \in R$, 最大叶节点数为 L 。

S2: 确定模糊带的宽度 $\alpha > 0$, 初始化根节点, 令 $N_1(x) \equiv 1$, 树的深度 $d=1$ 。根据式 (10) 求解

线性参数 c_1 :

$$\min_{c \in R^{(n+1)/l}} I(c) = \sum_{i=1}^M \left| y_i - c^T \xi(x_i) \right|_c + \frac{\gamma}{2} \tilde{c}^T \tilde{c} \quad (10)$$

式中, \tilde{T} 为二叉树集合, $t_l \in \tilde{T}$ 为叶节点集合, $\tilde{c} = [\tilde{c}_{t_1}, \tilde{c}_{t_2}, \dots, \tilde{c}_{t_l}]^T$, $c = [c_{t_1}, c_{t_2}, \dots, c_{t_l}]^T$, $c_{t_l}^T \xi(x_i)$ 为模型输出值, 式中第一项是经验风险, 代表模型的误差, 第二项代表模型的复杂度, 参数 $\gamma > 0$ 为平衡因子, 实现模型复杂度与训练误差之间的折衷。

S3: 依次处理当前深度 d 的每一个节点: 划分该节点, 根据式 (11) - (14) 计算划分后左右子节点上的隶属度函数, 根据式 (10) 求出所有叶节点上的后件参数 $c_{\tilde{t}}$ 。

$$i) \text{ 对于根节点} \quad N_l(x) \equiv 1 \quad (11)$$

$$ii) \text{ 对于非根节点} \quad N_t(x) \equiv N_{p(t)}(x) \hat{N}_t(x) \quad (12)$$

$$\hat{N}_t(x) = \frac{1}{1 + \exp[-\alpha_t (c_{p(t)}^T \hat{x} - \theta_{p(t)})]} \quad (13)$$

$$\theta_{p(t)} = \sum_{i=1}^M N_{p(t)}(x_i) (c_{p(t)}^T \hat{x}_i) / \sum_{i=1}^M N_{p(t)}(x_i) \quad (14)$$

式中: $\hat{N}_t(x)$ 为非根节点上的辅助隶属度函数, $\theta_{p(t)}$ 为父节点上的数据中心, $|\alpha_t|$ 为模糊带宽度。

S4: 根据式 (15) 求计算输入样本对应的划分后的模型输出, 进而由式 (16) 计算均方根误差 (RMSE)。如果均方根误差小于划分前模型输出的均方根误差, 则保存此次划分, 否则, 处理当前层的下一个节点。

$$\hat{y}(x) = \sum_{t_l \in \tilde{T}} \mu_{t_l}(x) (c_{t_l})^T \hat{x} \quad (15)$$

$$RMSE = \sqrt{\sum_{i=1}^M (\hat{y}^i - y^i)^2 / M} \quad (16)$$

式中, \hat{x} 为 $[1, x^T]^T$, $\mu_{t_l}(x)$ 为 N_{t_l} 归一化隶属度函数, 定义如下:

$$\mu_{t_l}(x) = \frac{N_{t_l}(x)}{\sum_{t_l \in \tilde{T}} N_{t_l}(x)} \quad (17)$$

式中: N_{t_l} 为模糊子空间上定义的模糊集合, 对应的隶属度函数为 $N_{t_l}(x)$ 。

S5: 当前层处理完毕后, 如果模型输出的均方根误差小于允许最大误差或者当前二叉树的叶节点数大于 L , 则结束该次算法; 否则令 $d = d + 1$, 返回到第 S3 步, 继续算法。

3 VIP 指标实例验证

为了验证 VIP 指标的有效性, 本文使用参考文献[13]的燃煤锅炉历史运行数据来说明风煤比、排烟氧量、炉膛与风箱压差和燃烧器摆脚与锅炉效率的关系, 并与文献中的粗糙集方法进行了对比。

具体运行数据如表 1 所示:

表 1 燃煤锅炉运行数据

Tab. 1 The operation data of coal-fired boiler

工况	风煤比	排烟氧量/%	炉膛与风箱压差/kPa	燃烧器摆脚/%	锅炉效率/%
1	7.51	4.51	0.71	46.86	91.96
2	8.79	5.75	0.58	44.83	91.33
3	7.36	4.28	0.92	55.83	93.74
4	7.64	5.27	0.73	45.31	91.52
5	7.62	4.60	0.69	47.04	91.89
6	8.41	5.14	0.93	56.05	93.29
7	8.88	5.33	0.61	43.33	91.40
8	7.27	4.21	0.72	56.36	94.21
9	7.30	4.19	0.71	47.04	94.73
10	8.74	5.32	0.59	45.45	91.51

通过 PLS 对表 1 的 10 个工况数据进行重要信息提取和变量选择, 使用 (1) - (9) 计算 4 个变量的 VIP 指标分别为 0.9340、1.1442、0.8826 和 1.0195, 如图 1 所示。可以看出, 4 个变量中排烟氧量和燃烧器摆脚对锅炉效率的影响较大, 这与文献[13]采用粗糙集方法分析的结果一致, 证明了本文的 VIP 指标的有效性。




图 1 各变量的 VIP 指标

Fig.1 The VIP values of different variables

4 基于 PLS- ε -FT 的 NO_x 排放模型

4.1 研究对象与数据

本文研究对象为某电厂 600MW 的燃煤机组, 利用其历史数据进行重要特征变量信息提取和变量选择建立 NO_x 排放的 PLS- ε -FT 模型。试验历史数据如表 2 所示:

4.2 变量的 VIP 提取

根据相关机制分析, 选择机组负荷 (Load), 总给煤量 (F_{coal}), 炉膛总风量 (T_A), 一次风压 (P_A), 2 个一次风挡板开度 (V_{RA} 、 V_{RB}), 6 个二次风挡板开度 (S_{AC} 、 S_{BB} 、 S_{CA} 、 S_{CB} 、 S_{DB} 、 S_{DC}), 排烟温度 (T_{py}), 烟气含氧量 (O_2), 4 台磨煤机给煤量 (F_A 、 F_B 、 F_C 、 F_D), 4 台磨煤机通风挡板开度 (W_A 、 W_B 、 W_C 、 W_D) 作为全部的模型输入变量, 选择前 20 组历史数据作为训练样本, 由式 (1) - (9) 对训练样本的进行重要变量信息提取, 各个变量的 VIP 如表 3 所示:

表 2 某燃煤电厂的历史运行数据
Tab. 2 Historical data of coal-fired boiler

工况	Load/MW	$F_{coal}/t \cdot h^{-1}$	$T_A/m^3 \cdot s^{-1}$	P_A/kPa	$V_{RA}/\%$	$V_{RB}/\%$	$S_{AC}/\%$	$S_{BB}/\%$	$S_{CA}/\%$	$S_{CB}/\%$	$S_{DB}/\%$	$S_{DC}/\%$
1	378.219	154.762	1160.256	4.796	76.313	78.48	50	42.063	87.424	44.2	41.484	49.695
...
23	359.651	176.82	1141.941	4.85	76.313	78.358	49.939	42.033	87.393	44.17	41.484	49.634

工况	$T_{py}/^{\circ}C$	$O_2/\%$	$F_A/t \cdot h^{-1}$	$F_B/t \cdot h^{-1}$	$F_C/t \cdot h^{-1}$	$F_D/t \cdot h^{-1}$	$W_A/\%$	$W_B/\%$	$W_C/\%$	$W_D/\%$	$\rho(NO_x)/mg(Nm^3)^{-1}$
1	106.135	4.042	44.456	37.263	21.534	35.752	99.084	99.42	98.871	81.532	569.413
...
23	106.194	4.598	37.065	29.709	42.98	43.454	99.145	99.359	98.779	81.441	566.396

表 3 输入变量的 VIP
Tab. 3 VIP of input variables

变量	O_2	F_A	P_A	S_{CB}	F_C	F_D	F_B	S_{DB}	Load	T_A	T_{py}
VIP	1.9178	1.6572	1.3823	1.3643	1.3426	1.3424	0.9897	0.9778	0.9445	0.8939	0.8390

变量	S_{DC}	S_{AC}	W_D	V_{RA}	F_{coal}	S_{BB}	W_B	S_{CA}	W_A	V_{RB}	W_C
VIP	0.8258	0.6881	0.6817	0.6284	0.6272	0.6153	0.6047	0.5999	0.4522	0.3229	0.2172

4.3 模型结构

通过 PLS 对模型输入的所有变量进行重要变量信息提取, 得到相应的 VIP 指标(如表 3 所示), VIP 越大表明自变量对因变量的贡献作用就越大, 然后采用变量逐次加一交叉验证的方法, 进行变量选择, 选择出最优变量子集作为的模型输入。PLS- ε -FT 模型结构如图 2 所示:




图 2 PLS- ε -FT 模型结构

Fig.2 Structure of PLS- ε -FT model

4.4NO_x 排放特性建模

本文采用变量逐次加一交叉验证来进行变量选择, 确定模型的最优输入变量。主要将所有变量按照 VIP 从大到小的顺序逐次加一输入 ε -FT 模型, 并计算每次模型的 RMSE, 直至输入所有变量为止。其中, 将表 2 中的前 20 组数据作为模型训练样本, 后 3 组作为模型的测试样本, 记训练样本的模型 RMSE 为 P_{RMSE} , 记测试样本的 RMSE 为 Q_{RMSE} 。选择模型 Q_{RMSE} 为最小值时对应的输入变量作为模型的最优输入变量。输入变量个数与模型 P_{RMSE} 和 Q_{RMSE} 的关系分别如图 3 和图 4 所示。可以看出, 当输入变量个数为 17 时, 模型的 Q_{RMSE} 有最小值为 5.1798mg/Nm³, 此时 P_{RMSE} 为 0.0167mg/Nm³, 具有较高的预测精度和泛化能力。

力。




图 3 P_{RMSE} 与输入变量个数的关系

Fig.3 Relationship between P_{RMSE} and the number of input variables




图 4 Q_{RMSE} 与输入变量个数的关系

Fig.4 Relationship between Q_{RMSE} and the number of input variables

综上所述, 本文选择表 3 中的前 17 个变量作为模型的最优输入变量, 建立了基于 PLS- ε -FT 的 NO_x 排放特性预测模型。其效果如图 5 所示。可以看出, 该模型具有较高的预测精度和泛化能力。




图 5 模型对 NO_x 排放的预测

Fig.5 Model prediction of NO_x emission

4.5 模型对比

本文将 PLS- ε -FT 模型与其他方法建立的模型进行了对比, 结果如表 4 所示。其中, ε -FT 和 LSSVM 是未经过 PLS 变量选择建立的模型, LSSVM 模型中的正规化参数为 137.3762, 核函数为 2.7314。可以看出, LSSVM 模型的预测误差较大, PLS- ε -FT 模型预测误差最小, 泛化能力最强, 同时经过变量选择, 将 22 个输入变量降低到了 17 个变量, 降低了模型的复杂程度。

表 4 不同建模方法对比

Tab. 4 Comparison of different models

模型	RMSE (mg/Nm ³)	
	训练样本	测试样本
ε -FT	0.0097	9.8797
LSSVM	0.3651	14.0399
PLS- ε -FT	0.0167	5.1798

5 结论

本文通过 PLS 对 600MW 电站锅炉的历史运行数据进行了重要变量信息提取和变量选择, 得到了模型的最优输入变量子集, 从而建立了 NO_x 排放的 PLS- ε -FT 模型。并将该模型与 ε -FT 和 LSSVM 所建立的模型进行了对比。结果表明, 所建立的 PLS- ε -FT 模型能有效地降低模型的复杂程度, 提高模型的预测精度和泛化能力。

参考文献

[1] 肖海平, 张千, 王磊, 等. 燃烧调整对 NO_x 排放及锅炉效率的影响[J]. 中国电机工程学报, 2011, 31(8): 1-2.
XIAO Haiping, ZHANG Qian, WANG Lei, et al. Effect of combustion adjustment on emission and boiler efficiency[J]. **Proceedings of the CSEE**, 2010, 30(23): 19-23.

[2] 牛培峰, 肖兴军, 李国强, 等. 基于万有引力搜索算法的电厂锅炉 NO_x 排放模型的参数优化[J]. 动力工程学报, 2013, 33(2): 100-106.
NIU Peifeng, XIAO Xingjun, LI Guoqiang, et al. Parameter optimization for NO_x emission model of power plant boilers based on gravitational search algorithm[J]. **Journal of Chinese Society of Power Engineering**, 2013, 33(2): 100-106.

[3] 牛培峰, 麻红波, 李国强, 等. 基于支持向量机和果蝇优化算法的循环流化床锅炉 NO_x 排放特性研究[J]. 动力工程学报, 2013, 33(4): 267-271.
NIU Peifeng, MA Hongbo, LI Guoqiang, et al. Study on NO_x emission from CFB boilers based on support vector machine and fruit fly optimization algorithm[J]. **Journal of Chinese Society of Power Engineering**, 2013, 33(4): 267-271.

[4] 牛玉广, 沙超, 康俊杰. 基于数值模拟与试验运行数据的电站锅炉燃烧系统复合建模[J]. 动力工程学报, 2014, 34(10): 765-770.
NIU Yuguang, SHA Chao, KANG Junjie. Hybrid modeling of boiler

combustion system based on numerical simulation and experimental data[J]. **Journal of Chinese Society of Power Engineering**, 2014, 34(10): 765-770.

[5] 张文广, 张越, 孙亚洲, 等. 基于最小二乘支持向量机和改进的果蝇优化算法的 CFB 锅炉燃烧优化[J]. 热力发电, 2016. (已录用)
ZHANG Wenguang, ZHANG Yue, SUN Yazhou, et al. Combustion optimization for CFB boiler based on least square support vector machine and modified fruit fly optimization algorithm[J]. **Thermal Power Generation**, 2016.

[6] 顾燕萍, 赵文杰, 吴占松. 基于最小二乘支持向量机的电站锅炉燃烧优化[J]. 中国电机工程学报, 2010, 30(17): 91-97.
GU Yanping, ZHAO Wenjie, WU Zhansong. Combustion optimization for utility boiler based on least square-support vector machine[J]. **Proceedings of the CSEE**, 2010, 30(17): 91-97.

[7] 姚健. 一类非线性系统的智能化建模方法研究[D]. 北京: 北京航空航天大学, 2009.
YAO Jian. Research on intelligent modeling for a class of nonlinear systems[D]. **Beijing University of Aeronautics and Astronautics**, 2009.

[8] MAO Jianqin, ZHANG Jiangang, YUE Yufang, et al. Adaptive-tree-structure-based fuzzy inference system. **IEEE Transactions on Fuzzy Systems**, 2005, 13(1): 1-12.

[9] 张文广, 孙亚洲, 刘吉臻, 等. 基于自适应模糊树推理和果蝇优化算法的 CFB 锅炉燃烧优化[J]. 动力工程学报, 2016, 36(2): 84-90.
ZHANG Wenguang, SUN Yazhou, LIU Jizhen, et al. Combustion optimization for CFB boiler based on adaptive fuzzy inference and fruit fly optimization algorithm[J]. **Journal of Chinese Society of Power Engineering**, 2016, 36(2): 84-90.

[10] 康俊杰, 牛玉广, 刘敬, 等. 基于模糊树模型的电站锅炉燃烧系统建模[J]. 电站系统工程, 2014, 30(6): 1-4.
KANG Junjie, NIU Yuguang, LIU Jing, et al. Modeling for utility boiler combustion system based on fuzzy tree model[J]. **Power System Engineering**, 2014, 30(6): 1-4.

[11] ZHANG Wei, MAO Jianqin. Fuzzy tree modeling based on ε -insensitive learning method[C]//**Proceedings of Conference on Industrial Electronics and Applications**, IEEE, Piscataway, NJ, United States, 2011.

[12] 刘吉臻, 吕游, 杨婷婷. 基于变量选择的锅炉 NO_x 排放的最小二乘支持向量机建模[J]. 中国电机工程学报, 2012, 32(20): 102-107.
LIU Jizhen, LV You, YANG Tingting. Least squares support vector machine modeling on NO_x emission of boilers based on variable selection[J]. **Proceedings of the CSEE**, 2012, 32(20): 102-107.

[13] 杨婷婷. 基于数据的电站节能优化控制研究[D]. 北京: 华北电力大学, 2010.
YANG Tingting. Data-based research on Energy-saving optimization and control of power station[D]. **North China Electric Power University**, 2010.